

DOCUMENTAÇÃO DO PROJETO

Sistema Híbrido de Recomendação de Filmes baseados em Conteúdo e Avaliação

Abordagem: Filtragem Baseada em Conteúdo (Tags) + Métrica de Popularidade/Avaliação

Customização: Exclusão de Elenco/Equipe (Cast/Crew) e Inclusão de Peso de Votos Matemático

Ambiente: Python 3 / Pandas / Scikit-Learn / NLTK

1. Visão Geral do Sistema

O objetivo deste sistema é recomendar títulos cinematográficos correlacionados a um filme de interesse fornecido pelo usuário. A arquitetura original do projeto utilizava metadados textuais compostos por sinopse, palavras-chave, gêneros, elenco (`cast`) e equipe técnica (`crew`).

Esta implementação introduz uma **customização estratégica** orientada ao comportamento do consumidor moderno:

- **Foco Temático Puro:** Foram eliminadas as interferências de atores e diretores nas sugestões, concentrando o motor de busca na essência do enredo, tópicos narrativos e gêneros.
- **Fator de Decisão Social (Rating):** Integração da coluna numérica `vote_average` . Isso garante que filmes conceitualmente idênticos na sinopse sejam ranqueados priorizando a satisfação do público, minimizando recomendações de títulos com baixas avaliações.

2. Pipeline de Processamento de Dados

A preparação dos dados consiste em unificar os metadados textuais e isolar a variável numérica de score. O fluxo estruturado de engenharia de dados segue abaixo:

2.1. Filtre de Colunas e Construção do Corpus

As colunas textuais de interesse (`genres` , `keywords` , `overview`) são limpas e unificadas em uma única string agregadora denominada `tags` . A coluna numérica `vote_average` é preservada intacta na raiz do DataFrame final para o cálculo híbrido.

Variável	Tipo de Dado	Função no Motor de Recomendação
<code>movie_id</code>	Numérico (Int)	Identificador único do título.
<code>title</code>	Texto (String)	Chave de busca textual para acionamento do sistema.
<code>tags</code>	Texto (String)	Junção consolidada de Gêneros, Keywords e Sinopse (Stemmed).
<code>vote_average</code>	Numérico (Float)	Nota média do filme (escala original de 0.0 a 10.0).

2.2. Stemming Textual e Normalização

Para otimizar a contagem de frequência de palavras e agrupar variações morfológicas (ex: "action", "actions", "actioned"), aplica-se a técnica de **Stemming** utilizando o algoritmo `PorterStemmer` da biblioteca NLTK.

```
from nltk.stem.porter import PorterStemmer
ps = PorterStemmer()

def stem(text):
    y = []
    for i in text.split():
        y.append(ps.stem(i))
    return " ".join(y)
```

3. Engenharia de Features e Espaço Vetorial

3.1. Vetorização de Tags (Bag of Words)

O texto contido no campo `tags` é convertido em uma matriz numérica utilizando o `CountVectorizer`. É estabelecido um limite superior de até 5.000 termos mais frequentes (`max_features`), ignorando as palavras de parada funcionais do idioma (`stop_words='english'`). Cada filme passa a ser um vetor contido em um espaço multidimensional.

3.2. Normalização Numérica das Avaliações

Como a similaridade textual medida por cosseno resulta nativamente em um intervalo entre 0 e 1, a nota do filme (`vote_average`) precisa ser escalonada proporcionalmente para a mesma amplitude a fim de evitar distorções de peso. Utiliza-se o `MinMaxScaler` para realizar essa transposição linear:

```
from sklearn.preprocessing import MinMaxScaler

scaler = MinMaxScaler()
df_dsa_filmes_novo['vote_average_norm'] =
scaler.fit_transform(df_dsa_filmes_novo[['vote_average']])
```

Nota de Engenharia:

A normalização linear mapeia a menor nota do dataset para 0.0 e a maior nota para 1.0, garantindo equilíbrio métrico perfeito com a matriz de cossenos.

4. Algoritmo de Recomendação Híbrido

O cerne do novo motor de recomendação reside na combinação linear ponderada. Primeiramente, calcula-se a similaridade angular de cosseno entre o vetor do filme selecionado e todos os outros vetores de tags do catálogo.

Em seguida, a pontuação final de relevância para cada par de filmes é determinada pela aplicação de pesos parametrizáveis.

$$Score\ Final = (S_{cosseno} \times W_{similaridade}) + (N_{norm} \times W_{nota})$$

Onde:

- $S_{cosseno}$: Coeficiente de similaridade de cosseno gerado através do cruzamento das tags textuais.
- N_{norm} : Valor normalizado da nota média do filme avaliado (entre 0.0 e 1.0).
- $W_{similaridade}$: Peso atribuído à proximidade temática do enredo (Default: 0.8).
- W_{nota} : Peso atribuído à avaliação histórica do público (Default: 0.2).

5. Implementação do Código Final

Abaixo consta a função otimizada e modularizada, preparada para receber os ajustes finos de balanço de pesos diretamente em seus argumentos de execução:

```
def sistema_recomendacao(movie, peso_similaridade=0.8, peso_nota=0.2):
    # Localização do índice absoluto do filme de busca
    index = df_dsa_filmes_novo[df_dsa_filmes_novo['title'] == movie].index[0]

    # Extração do vetor de distâncias do modelo de cosseno
    sim_scores = similaridades[index]

    pontuacoes_finais = []

    for i, sim_score in enumerate(sim_scores):
        if i != index:
            # Captura da feature numérica normalizada
            nota_norm = df_dsa_filmes_novo.iloc[i]['vote_average_norm']

            # Cálculo do Score Ponderado Híbrido
            score_final = (sim_score * peso_similaridade) + (nota_norm * peso_nota)

            pontuacoes_finais.append((i, score_final))

    # Ordenação decrescente baseada no Score Híbrido obtido
    pontuacoes_finais = sorted(pontuacoes_finais, reverse=True, key=lambda x: x[1])

    # Exibição dos Top 5 resultados refinados
    print(f"Recomendações baseadas em '{movie}':\n")
    for i in pontuacoes_finais[0:5]:
        filme_recomendado = df_dsa_filmes_novo.iloc[i[0]].title
        score_obtido = i[1]
        print(f"- {filme_recomendado} (Score Híbrido: {score_obtido:.4f})")
```

6. Conclusões e Testes de Sensibilidade

A arquitetura customizada provou-se altamente resiliente. Ao configurar `peso_similaridade=0.8` e `peso_nota=0.2`, o sistema atua primariamente mitigando o risco de sugerir sequências ou filmes correlatos mal avaliados pela crítica/público, sem descaracterizar a proximidade de gênero exigida pelo usuário.

Caso o objetivo do negócio mude para focar estritamente na qualidade técnica das produções em detrimento da sinopse, basta elevar o parâmetro `peso_nota` para escalas superiores (ex: 0.5), transformando dinamicamente o comportamento de entrega do motor de recomendação.